


AI智能体知识库系统 · 技术路线说明

文档版本	修改日期	说明
V1.0	2026-08-10	宏观技术方案（现行架构）

1. 总体路线

系统是一套面向 GIS 产品技术资料的 **本地 RAG（检索增强生成）知识库问答** 方案，技术主线为：



三条硬原则：

- 1. **答案事实来自文本块（chunk）**：LLM 的 context 是检索到的正文；引用编号绑定真实来源。
- 2. **图谱不充当第二套问答引擎**：只用于实体消歧、扩召回相关块、改写检索 query、对已召回结果加减分。
- 3. **管线式编排，而非独立 Agent 调度服务**：问答在 FastAPI 单体中按固定阶段执行，失败可降级，不做多轮工具反思循环。

2. 总体架构

2.1 四层架构图

原版规划为「交互层 → Agent Core（意图/规划/工具/反思） → Tools → Storage」。

现状为同一套四层叙事，但中间两层改为 **管线式 RAG**（无独立 Agent 调度服务、无反思迭代）：

用户交互层（前端 Vue3）						
对话界面	博客管理	知识块审核台	质量仪表盘	图谱候选审批	图谱画布	QA调试

| HTTP / SSE

智能体核心层（现状 = FastAPI 问答管线）						
歧义预检	→	上下文文化	→	QueryPlanner	→	Hybrid检索
clarify		多query		意图/top_k		±图融合
						引用/SSE
决策逻辑：提问前可反问澄清 → 再正式检索；图失败/改写失败则降级纯文本路；无反思循环						

|

能力层（对应原版 Tools，现为服务模块）						
向量+BM25	图谱扩召	用户反问	元数据过	Intent	Rerank	文档入库
Hybrid	回+改写	clarify	滤/锚定	加减分	(可选)	扫描分块
（原版 Tool-05 空间计算：未实现）						

|

数据层（Storage）		
向量数据库	关系数据库	文件/JSON 存储
ChromaDB（锁定版本）	SQLite	watch_directory
知识块文本+向量	entities/aliases/	uploads / 博客目录
+ section 元数据	relations/links/	domain_catalog /
+ review_status	fields/procedures/	product_backbone /
	candidates 等	policies / 歧义种子

检索与图谱在架构中的位置（对应原版「工具调用」）：

能力	作用	是否写入答案事实
Hybrid 文本检索	主召回通道：向量 Similarity // BM25 → RRF；只取 review_status=approved	是（chunk 原文进 context）
图谱扩召回 + 融合	实体链接 → 关系扩展 → entity_chunk_links 取块 → 与文本路加权融合（席位控噪）	否（仍用块原文）
图辅助改写 query	中量图摘要 → helper LLM 产出额外检索 query	否
Graph Intent 评分	alias↑ / different_from↓ 等，改已召回块排序（可不依赖开图开关）	否
回答侧实体提示	prompt 消歧提示，声明非事实来源	否

3. 分层架构

层	技术选型	职责
交互层	Vue 3 + TypeScript + Vite	对话（SSE）、审核、图谱画布/ 候选审批、质量与调试
服务层	FastAPI（Python）	入库扫描、问答管线、审核与图谱管理 API
检索与生成	LangChain 编排；Embedding / LLM 多 provider（Ollama / OpenAI / Google 等）	Hybrid 召回、可选 Rerank、prompt 组装与流式生成
向量存储	ChromaDB	chunk 正文、embedding、章节/分类/ 审核等元数据
图谱存储	SQLite	实体、别名、关系、实体-chunk 链接、抽取候选 staging
文件与策略	本地目录 + JSON	监视入库目录、产品主干、领域目录、意图策略、反问种子等
部署	本地进程或 Docker 双容器（rag-service + rag-web）	API 与静态前端分离；可选 gpu-agent 显存监控

4. 数据技术路线

4.1 双存储分工

存储	存什么	在问答中的角色
ChromaDB	可检索正文 + 向量 + section_* / doc_category / review_status / kb_name 等	事实主库 ：检索命中后进入 LLM context
SQLite 图谱	实体、别名、关系、entity_chunk_links、字段/流程、抽取候选	结构辅库 ：通过链接把「实体邻居」映射回 chunk_id，再回到向量库取文

桥接关键：entity_chunk_links（实体 → chunk_id）。图侧召回最终仍落到向量库中的文本块。

4.2 知识组织

- **两个知识库**：按目录约定分为「已发布文章」「文章附件」，检索可按 kb_name 过滤。
- **文档分类**：chunk 级 doc_category 枚举（产品/业务域）；领域分层另由 domain_catalog 等 JSON 描述，经同步进入图谱建设链路。
- **审核门禁**：新块默认 pending；检索默认只使用 approved。
- **产品关系主干**：产品/服务等稳定结构以 JSON 主干维护，经审批同步写入正式图谱，供链接与扩展使用。

5. 文档入库技术路线

监视目录 / 上传 / 博客同步

- 哈希去重
- 解析（章节优先；表格转 Markdown；图片/视频经视觉描述）
- 清洗（域代码、目录噪声等）
- 分块（标题硬边界 + embedding 语义边界；表格/代码整块保护；异常则滑窗降级）
- 写入 Chroma（pending）+ 更新文件索引 + 维护 BM25 索引
- 人工审核通过后进入可检索集合

图谱建设与扫描入库**解耦**：规则抽取（章节路径/表字段/配置块等）± LLM 补实 → 候选批次 → 人工审批 → apply 正式库。避免扫描当下直接污染正式关系数据。

6. 问答检索技术路线（核心）

6.1 主路径：文本 Hybrid RAG

提问

- （可选）歧义预检：选项澄清后再检索
- 对话上下文化 / 多 query 构造
- 检索计划（意图 → top_k、是否精排等）
- Hybrid：向量 Similarity // BM25 → RRF 融合
- （可选）Cross-Encoder 精排
- 后处理加权与裁剪（章节/表格结构、token 预算等）
- LLM 生成（同步或 SSE）+ 确定性引用与证据

主路径保证：即使不开图谱，系统仍是完整可用的文本 RAG。

6.2 辅路径：图谱四类介入

在主路径关键节点注入，可叠加，均可降级跳过：

介入方式	技术动作	影响对象
Intent 评分	用别名、different_from、字段/章节等信号对已召回块加减分	排序
图扩召回 + 融合	问题链实体 → 沿关系扩展 → entity_chunk_links 取块 → 与 Hybrid 结果加权融合（限制纯图路席位、保护文本 top1）	候选集合与排序
图辅助改写 query	中量图摘要（名/别名/兄弟关系类型/路径词等，不喂证据正文）→ 辅助模型改写检索语句并入 Hybrid	召回 query
回答侧消歧提示	已链接实体时，在 system 中附加别名/易混提示，并声明非事实来源	prompt，不增加事实通道

配置上可将「图扩召回/改写」整体关闭；Intent 评分可独立于扩召回开关工作。

6.3 生成与治理

- Context 只放检索得到的 chunk 原文（及显式开启的外部搜索结果）。
- 无足够依据时先给出未命中提示；允许配置「通用知识补充」但与知识库结论分离标注。
- 来源编号、文件名、页码（或「无页码」）、原文片段由后端确定性生成，禁止伪造页码与虚构引用。

7. 智能体工作流程

原版为 12 步 Agent（预检得分阈值 → 反问 → 正式检索 → 图谱扩展 → 重排 → 生成 → 偏好记忆）。
现状按下列管线执行（实现入口： rag.py 等服务模块）：

步骤	阶段	动作	决策点
1	感知	接收用户问题 + 对话历史（前端/ 可选后端聊天记录）	闲聊正则 → 直接 LLM， 跳过检索；敏感 → 拒答
2	歧义预检	POST /query/clarify：LLM 主判 + 规则种子降级	命中 → 前端反问卡片， 用户带过滤条件再问； 否则 继续
3	上下文文化	历史改写独立问题 + 多 query + 来源锚点； 失败启发式	—
4	意图/计划	QueryPlanner：流程/部署/排错/对比等 → top_k、是否 rerank 等	—
5	图谱准备 （可选）	graph_retrieval.enabled=true 时：实体链接 → 关系扩展 → 经 entity_chunk_links 取图侧 chunk；可选图辅助改写 query	失败 → fallback 纯文本路
6	正式检索	Hybrid：向量 Similarity // BM25 → RRF；过滤 approved；可选 kb/分类/实体锚定	—
7	图谱融合 （可选）	文本路与图侧块加权融合； max_graph_only_slots + protect_text_top1 控噪	关图则跳过
8	重排序 （可选）	Cross-Encoder Rerank；生产 CPU 默认关， 本地可开	全局 reranker.enabled 三层门控
9	后处理评分	结构化加权（表格/章节等）+ Graph Intent （alias / different_from / field / section）	Intent 不依赖 开图开关
10	上下文组装	Token 预算裁剪 + 历史摘要；可选联网搜索 （显式开启）	—
11	生成答案	chunk 原文（编号）进 prompt； 若已链实体可附加 消歧提示（非事实） → LLM （同步/SSE）	无依据先输出未命中提示； 可选通用知识补充
12	溯源与证据	确定性来源引用 + 证据包；可选 QA trace 全流程记录	—

步骤	阶段	动作	决策点
13	反馈	有用/无用 → user_feedbacks	无 user_preferences 记忆跳过反问

与原版步骤 7-9 的对应关系：

- **正式检索** = 现状 Hybrid（主路径）。
- **图谱扩展** = 现状「先链实体再取块再融合」，不是「仅用已命中 chunk 反查 links 扩 1 跳」这一种写法；并增加图改写 query、Intent 加减分、回答侧消歧提示。
- **答案依据**始终是 Top 上下文中的 **chunk 文本**，不是关系句子。

8. 业务流程详细说明

8.1 文档入库流程

【开始】

↓

① 文档进入 watch_directory / 上传接口 / 博客爬取或发布同步

↓

② 系统自动（定时约 30 分钟或 POST /scan）：

- a. SHA-256 哈希去重（移动/重命名可追踪）
- b. 解析（md/docx/txt 优先章节切片；pdf/doc；Excel→Markdown 表；图片/视频→视觉描述）
- c. 清洗（Word 域代码、纯目录/纯链接/噪声）
- d. 分块（章节硬边界 + 语义边界；表格/代码结构保护）
- e. 向量化写入 Chroma，review_status=pending
- f. 更新 file_index；重建 BM25；清查询缓存
（图谱抽取不在本步自动 apply 进正式库）

↓

③ 业务员在【知识块审核工作台】处理 pending：

- 通过 → approved（可被检索）
- 驳回 → rejected
- 可改章节标题、doc_category
- 无合并/拆分/块内改文 → 切错则驳回后由开发侧重切

↓

④ approved 后进入检索集合

↓

【结束】

8.2 用户问答流程（含反问场景）

【开始】

↓

① 用户在【智能对话页面】输入问题

↓

② 闲聊/敏感分流；否则进入问答管线

↓

③ 提问前歧义预检（/query/clarify）

└─ 命中 → 反问卡片 → 用户选择过滤条件 → 继续

└─ 未命中 → 继续

↓

④ 上下文文化 + QueryPlanner

↓

⑤ [可选] 图谱准备：链接实体 / 扩召回取块 / 改写检索 query

↓

⑥ Hybrid 正式检索（approved + 可选分类/知识库过滤）

↓

⑦ [可选] 图侧与文本路融合（席位控噪 + 保护文本 top1）

↓

⑧ [可选] Rerank → 后处理（结构化加权 + Graph Intent）

↓

⑨ 组装 context（仅 chunk 原文 + 可选实体消歧提示）→ LLM 生成（SSE）

↓

⑩ 展示来源/证据；用户反馈有用/无用

↓

【结束】

8.3 图谱维护流程

【开始】

↓

- ① 方式一：规则管线 ± LLM 抽取 → extraction_candidates
 - SectionPath / TableField / ConfigBlock 等确定性抽取
 - 可选 LLM 语义补实（配置开关）
 - 指纹去重进批次

↓

- ② 方式二：产品主干 / domain_catalog / Profile 等 JSON 同步进 staging

↓

- ③ 审批：【图谱候选审批台】或 CLI (run_graph_build.py)
 - 分拆审批：禁止对敏感 mode 滥用 --approve-all
 - apply 需三重确认（DB 路径 / 批次 / 备份）

↓

- ④ 写入正式表：entities / aliases / relations / entity_chunk_links / fields / ...

↓

- ⑤ 画布：查看、过滤、展开邻居；主干预览改 JSON（不直接当正式写）

↓

- ⑥ 审计 / Stale 清理 / 质量 / Task8.1 Gate 等运维命令

↓

- ⑦ 运行时：仅按配置介入检索管线（Intent / 扩召回融合 / 改写 / 消歧提示）

↓

【结束】

9. 模型与推理路线


角色	用途	接入方式
主问答 LLM	最终回答	按配置 provider（本地 Ollama 或外部 API）
辅助 LLM	澄清、改写、摘要、轻量判断	可与主模型分离，通常更小/更便宜
Embedding	入库与向量检索	独立模型；变更后需重建向量库
视觉模型	图片/视频帧描述	可选
Reranker	Cross-Encoder 精排	可选依赖；生产可关，避免 CPU 重负载

可选 **GPU 显存监控**：按配置表估计模型占用，在显存不足时推荐或降级到可装下的模型；监控不可用时保守不自动降级。

10. 前端与运维面

能力面	技术要点
对话	SSE 流式；来源/证据展示；分类与知识库过滤；可选联网
知识治理	知识块审核；图谱候选审批与 apply；画布查看与主干预览
质量	审核与反馈类指标仪表盘；问答过程 trace（调试）
运维	受控重建（备份、清库、重扫、一致性断言、BM25 重建）；配置分环境（本地/混合/生产模板）

11. 技术路线一览（一张图）



一句话归纳：以 Hybrid 文本检索 + LLM 引用生成 为骨干，以 知识图谱为检索增强层，以 审核门禁与候选审批 控制进入正式库与可检索集合的数据质量。

文档结束