

AI智能体知识库系统 · 产品需求说明书（PRD · 现状版）

文档版本	修改日期	修改人	修改内容
V1.0	2026-06-29	—	原始规划稿（见同目录 AI智能体知识库系统-产品需求说明书(PRD).md）
V2.0-现状	2026-08-10	—	按原版章节骨架与写法，改写为「当前系统实际形态」说明

说明：本文档仿照原版 PRD 的章节结构与表述方式，描述截至 **2026-08-10** 已落地的系统。
阅读时可与原版逐节对照：同标题下写的是「现在做成了什么」，不是「还打算做什么」。

一、项目概述

1.1 项目背景

当前系统已从早期的 Open WebUI + Ollama 基础 RAG，演进为 **自研 Vue3 前端 + FastAPI 单体后端** 的本地知识库问答系统（多 provider 模型、Hybrid 检索、可选 GraphRAG）。原版 PRD 中列出的核心问题，落地情况如下：

问题编号	原问题描述	现状（2026-08-10）
P1	多份手册中相同名词含义不同，AI回答混乱	部分缓解：检索前歧义预检（反问卡片）+ Graph Intent (alias / different_from) + 回答侧实体消歧提示； 无 用户偏好记忆表
P2	知识块按字数硬切分，丢失章节结构语义	已解决： 章节硬边界 + embedding 语义切块；表格/代码结构保护；异常时滑窗降级
P3	文档无分类、无关联关系	部分解决： chunk 带 doc_category（9 类枚举）+ SQLite 图谱（实体/关系/实体-chunk 链接）；分类 不是 原版树形分类表
P4	系统不会反问	已有： POST /query/clarify + 前端选项卡片；规则 JSON 种子 + LLM 主判； 无 30 秒超时 / 偏好跳过

问题编号	原问题描述	现状（2026-08-10）
P5	业务人员无法干预和修正知识数据	部分解决 ：审核台可改章节标题/分类、通过/驳回； 无 块内文本编辑、合并/拆分、审核台内关联实体
P6	无空间数据对接能力	仍预留 ：仅 geo_wkt 字段（恒为 None），无地图功能

1.2 项目目标

原版目标与达成情况：

目标编号	目标描述	原量化指标	现状
G1	回答准确率提升至85%以上	人工抽检100题	黄金集 FR-10 v4： 39/45 = 86.67% （live 约 2537 chunks）
G2	支持知识块人工审核与修正	业务员可独立操作	 审核台通过/驳回/改标题与分类；  无合并拆分与块文本编辑
G3	建立文档分类与知识图谱关系	复杂问题能跨文档关联	 分类元数据 + 图谱建设/审批；运行时图扩召回辅助找块（生产模板默认关图）
G4	系统具备主动反问能力	歧义时弹出选项卡片	 提问前反问卡片（2~4选项）
G5	预留地图展示对接接口	空间字段存在、渲染暂不实现	仅保留 geo_wkt ； geo_bbox / place_name 未落地

1.3 系统角色定义

系统当前**无登录与权限体系**，页面均开放。按使用方式对应原版角色：

角色	职责（现状）	使用频率
普通用户	提问、追问、查看来源/证据、反馈有用/无用、可选联网搜索、切换知识库/分类/模型	高频

角色	职责（现状）	使用频率
业务审核员	审核知识块（通过/驳回、改标题/分类）；图谱候选审批与应用；画布查看/主干预览编辑	中频
系统管理员	配置/CLI、受控重建、知识库一致性、Docker 部署、质量仪表盘； 无 分类树管理页与版本切换页	低频
后台系统	定时扫描入库、清洗分块向量化、BM25 重建、图谱抽取候选（规则±LLM）、反馈统计	持续运行

二、总体架构

2.1 四层架构图

原版规划为「交互层 → Agent Core（意图/规划/工具/反思）→ Tools → Storage」。
现状为同一套四层叙事，但中间两层改为 **管线式 RAG**（无独立 Agent 调度服务、无反思迭代）：

用户交互层（前端 Vue3）						
对话界面	博客管理	知识块审核台	质量仪表盘	图谱候选审批	图谱画布	QA调试

| HTTP / SSE

智能体核心层（现状 = FastAPI 问答管线）						
歧义预检	→	上下文文化	→	QueryPlanner	→	Hybrid检索
clarify		多query		意图/top_k		±图融合
						引用/SSE
决策逻辑：提问前可反问澄清 → 再正式检索；图失败/改写失败则降级纯文本路；无反思循环						

|

能力层（对应原版 Tools，现为服务模块）						
向量+BM25	图谱扩召	用户反问	元数据过	Intent	Rerank	文档入库
Hybrid	回+改写	clarify	滤/锚定	加减分	(可选)	扫描分块
（原版 Tool-05 空间计算：未实现）						

|

数据层（Storage）		
向量数据库	关系数据库	文件/JSON 存储
ChromaDB（锁定版本）	SQLite	watch_directory
知识块文本+向量	entities/aliases/	uploads / 博客目录
+ section 元数据	relations/links/	domain_catalog /
+ review_status	fields/procedures/	product_backbone /
	candidates 等	policies / 歧义种子

检索与图谱在架构中的位置（对应原版「工具调用」）：

能力	作用	是否写入答案事实
Hybrid 文本检索	主召回通道：向量 Similarity // BM25 → RRF；只取 review_status=approved	是（chunk 原文进 context）
图谱扩召回 +融合	实体链接 → 关系扩展 → entity_chunk_links 取块 → 与文本路加权融合（席位控噪）	否（仍用块原文）
图辅助改写 query	中量图摘要 → helper LLM 产出额外检索 query	否
Graph Intent 评分	alias↑ / different_from↓ 等，改已召回块排序（可不依赖开图开关）	否
回答侧实体提示	prompt 消歧提示，声明非事实来源	否

现行契约：**业务事实只来自检索到的 chunk 原文**（联网结果须显式开启并标「外部来源」。关系边 / evidence_text 不作为独立事实通道。

2.2 数据流转总览

阶段	触发动作	数据流转（现状）
入库	放入 watch_directory / 上传 / 博客爬取或同步；定时扫描或 POST /scan	文档 → 清洗 → 章节/语义分块 → 向量化入 Chroma（pending）→ 更新 file_index + BM25；图谱抽取为 独立 extract→候选→审批→apply，不与扫描同步写正式库
审核	打开知识块审核台	筛选 pending → 改标题/分类 → 通过/驳回（批量或「通过全部筛选」）； 无 合并/拆分/块内改文/审核台关联实体
检索	对话页提问	问题 → （可选反问）→ 上下文文化/多 query → Planner → Hybrid → （可选图扩召回融合/改写）→ （可选 Rerank）→ Intent 等后处理 → LLM 生成 + 引用/证据
反馈	用户点「有用/无用」	写入 user_feedbacks → 质量仪表盘统计；差评可重置对应 chunk 待审

三、数据层详细设计

3.1 向量数据库（ChromaDB）

原版问题「固定字数硬切」：现状已改为章节硬边界 + embedding 语义边界；表格/代码不切断；embedding 异常时滑窗降级。

每个 Chunk 入库时携带的主要字段（与运行时 metadata 对齐）：

字段名	类型	必填	说明	示例/备注
chunk_id	String	是	全局唯一知识块 ID	由入库流程生成
text	Text	是	知识块正文	—
embedding	Vector	是	文本向量	由配置的 embedding 模型生成
metadata.source / file_path	String	是	来源文件	如手册路径
metadata.doc_category	String	是	文档分类（9 类枚举，非树表）	StampServer / StampTools / ...
metadata.section_title	String	是	章节标题	—
metadata.section_path	String	是	章节完整路径	—
metadata.section_index / chunk_in_section	Integer	是	章节序 / 块在章节内序号	—
metadata.page	Integer/ 空	否	页码； 无页码类型显示「无页码」	TXT/MD/图片/视频等
metadata.kb_name	String	是	「已发布文章」或「文章附件」	按目录规则
metadata.review_status	Enum	是	pending / approved / rejected	检索默认只返回 approved
metadata.geo_wkt	String	否	预留空间字段	恒为 None；无 bbox/place_name

知识库约定： watch_directory/已发布文章/ → kb_name=「已发布文章」；其余 → 「文章附件」。

3.2 关系数据库（SQLite， data/rag_relational.db ）

原版规划 **6 张表**（含分类树、歧义规则表、用户偏好表）。

现状为图谱 schema（约 9 张业务表 + 反馈等），**没有** doc_categories / disambiguation_rules / user_preferences SQL 表。

表：实体 entities

字段名	说明（现状）
name / canonical_name	名称 / 规范名（唯一约束按实现）
entity_type	如 Product / Service / Section / Field / Error 等 （以正式库与主干为准）
doc_category	可选归属分类
confidence / review_status / properties_json / created_by	置信度、审核态、扩展属性、来源（如 seed:product_backbone）

别名不在实体行内逗号拼接，而在独立表 **aliases**（alias → entity_id，可带 source_chunk_id / evidence_text）。

表：关系边 relations（对应原版 entity_relations）

字段名	说明（现状）
source_entity_id / target_entity_id	两端实体
relation_type	如 belongs_to、different_from、defined_in、has_field 等
confidence / evidence_text / source_chunk_id / review_status	置信度、证据、血缘 chunk、审核态
唯一约束	(source, target, type)

运行时扩召回取证据块主要靠 **entity_chunk_links**，不是靠把 evidence_text 直接塞进答案。

表：实体-知识块关联 entity_chunk_links（核心关联，同原版定位）

字段名	说明（现状）
entity_id / chunk_id	实体 ↔ 向量库 chunk

字段名	说明（现状）
link_type / section_path / page_label / evidence_text / source	链接类型与展示/血缘信息

作用：图扩召回（模式 2）经此表加载图侧 Document，再与 Hybrid 结果融合。

表：字段 / 流程（原版无，现状新增）

表	用途
fields	限定名 Field（如 管线点表.管点编号 ），Task 8.2
procedures / procedure_steps	操作流程与步骤

表：抽取 staging（原版无，现状建设主路径）

表	用途
extraction_batches	抽取/同步批次（mode、快照哈希、统计）
extraction_candidates	候选（kind、fingerprint 去重、payload、status：pending/approved/rejected/applied）

原版表5/表6 的替代形态

原版表	现状
disambiguation_rules	data/disambiguation_rules.json 种子；LLM 主判是否反问
user_preferences	未实现
doc_categories 树表	chunk doc_category 枚举 + data/domain_catalog.json

反馈表 user_feedbacks

记录对话反馈（有用/无用），供质量仪表盘与差评回审。

3.3 数据淘汰与版本管理机制

机制	原版设计	现状
软删除	is_active=false	用 review_status=rejected （或重建剔除）；检索不返回非 approved

机制	原版设计	现状
版本标记	同文件多版本共存 + 切换界面	无版本切换页；变更靠重新入库/受控重建（备份→清空→重扫→一致性断言→BM25）
定期清理	180 天物理删	无该定时策略；图谱侧有 Stale 链接清理、审计等运维命令

四、智能体核心功能设计

4.1 智能体工作流程

原版为 12 步 Agent（预检得分阈值 → 反问 → 正式检索 → 图谱扩展 → 重排 → 生成 → 偏好记忆）。
现状按下列管线执行（实现入口：rag.py 等服务模块）：

步骤	阶段	动作	决策点
1	感知	接收用户问题 + 对话历史（前端/可选后端聊天记录）	闲聊正则 → 直接 LLM，跳过检索；敏感 → 拒答
2	歧义预检	POST /query/clarify：LLM 主判 + 规则种子降级	命中 → 前端反问卡片，用户带过滤条件再问； 否则 继续
3	上下文文化	历史改写独立问题 + 多 query + 来源锚点；失败启发式	—
4	意图/计划	QueryPlanner：流程/部署/排错/对比等 → top_k、是否 rerank 等	—
5	图谱准备 (可选)	graph_retrieval.enabled=true 时：实体链接 → 关系扩展 → 经 entity_chunk_links 取图侧 chunk；可选图辅助改写 query	失败 → fallback 纯文本路
6	正式检索	Hybrid：向量 Similarity // BM25 → RRF；过滤 approved；可选 kb/分类/实体锚定	—
7	图谱融合 (可选)	文本路与图侧块加权融合；max_graph_only_slots + protect_text_top1 控噪	关图则跳过
8	重排序 (可选)	Cross-Encoder Rerank；生产 CPU 默认关，本地可开	全局 reranker.enabled 三层门控
9	后处理评分	结构化加权（表格/章节等）+ Graph Intent （alias / different_from / field / section）	Intent 不依赖 开图开关

步骤	阶段	动作	决策点
10	上下文组装	Token 预算裁剪 + 历史摘要；可选联网搜索（显式开启）	—
11	生成答案	chunk 原文（编号）进 prompt； 若已链实体可附加 消歧提示（非事实） → LLM（同步/SSE）	无依据先输出未命中提示； 可选通用知识补充
12	溯源与证据	确定性来源引用 + 证据包；可选 QA trace 全流程记录	—
13	反馈	有用/无用 → user_feedbacks	无 user_preferences 记忆跳过反问

与原版步骤 7-9 的对应关系：

- **正式检索** = 现状 Hybrid（主路径）。
- **图谱扩展** = 现状「先链实体再取块再融合」，不是「仅用已命中 chunk 反查 links 扩 1 跳」这一种写法；并增加图改写 query、Intent 加减分、回答侧消歧提示。
- **答案依据**始终是 Top 上下文中的 **chunk 文本**，不是关系句子。

4.2 反问工具的行为规范

规范项	原版要求	现状
反问触发条件	预检得分<0.75 / 命中规则表 / 缺上下文	提问前 clarify：LLM 主判模糊/实体不确定；规则 JSON 作种子与降级
反问格式	可点击选项，非开放式	✅ 选项按钮
选项数量	2~4，可加「其他」	✅ 2~4
选项内容	显示文本 + 过滤条件 JSON	✅ 可带 doc_category / entity_name 等继续检索
超时处理	30 秒自动「综合回答」	❌ 未实现
记忆应用	user_preferences 跳过反问	❌ 未实现

五、前端页面功能清单

5.1 页面清单总览

序号	页面名称	用户角色	核心功能	相对原版
1	智能对话页面	普通用户	提问/追问、SSE 答案、来源与证据、反馈、反问卡片、分类/知识库/模型、联网、GPU 面板	✅ 已有（增强）
2	知识块审核工作台	业务审核员	筛选、列表/详情、改标题/分类、通过/驳回、批量与「通过全部筛选」	✅ 已有 (弱于原版编辑能力)
3	图谱画布	业务审核员/运维	Force/Dagre、过滤、渐进展开邻居、主干预览编辑、节点编辑/删除、证据展示	✅ 已有（无版本快照/节点合并）
4	博客管理	业务/运维	爬取/同步/预览/删除	原版无，现状有
5	质量控制仪表盘	运维	审核占比、满意率、孤立实体、待复核等	✅ 已有
6	图谱候选审批台	业务审核员	批次概览、批准、应用、质量判定	原版无独立页，现状有
7	问答证据调试	运维/开发	trace 回放、证据一致性	原版无，现状有
—	文档管理 / 分类管理 / 歧义规则管理 / 版本管理	—	—	❌ 未做 (入库靠监视目录+上传 API)

5.2 各页面核心交互定义

页面1：智能对话页面

交互元素	说明（现状）
输入框	文本；支持图片粘贴/上传（视觉问答）
发送按钮	触发提问 / 流式回答

交互元素	说明（现状）
答案卡片	Markdown 渲染 AI 正文
来源/证据面板	编号来源（文件名、页码或「无页码」、原文片段）+ 证据包
反馈按钮组	有用 / 无用
反问卡片	clarify 命中时展示 2~4 选项
分类/知识库/模型	doc_category 、kb 下拉、模型下拉（外部标注（外部））
开关	重排序、联网搜索、通用知识补充等
GPU 面板	显存与推荐/降级提示（配置启用时）

页面2：知识块审核工作台

交互元素	说明（现状）
筛选器	分类、审核状态、文件名
列表视图	文件名、章节、分类、状态、预览、操作
详情面板	来源信息；编辑章节标题、编辑分类
编辑操作	✗ 无块内文本编辑、合并、拆分；✅ 通过/驳回
关联操作	✗ 审核台内不关联实体（图谱侧另有建设/审批链路）
批量操作	勾选批量通过/驳回；「通过全部筛选结果」

页面3：图谱画布

交互元素	说明（现状）
画布	平移缩放；Force / Dagre 布局
节点/连线	按类型展示；产品链路与文档链路等过滤
交互	渐进展开邻居、搜索高亮、点击看详情与关联块/证据
编辑	节点编辑/删除；主干预览编辑（写 JSON，不直接写正式库）
未实现	原版：拖块建链、节点合并、版本快照回滚、画布「智能解析」一键抽取

页面5：质量控制仪表盘（对应原版页面5）

指标	说明	数据来源（现状）
已审核占比等	审核与质量核心卡	Chroma / 统计服务
孤立实体等	图谱健康	关系库 / 审计
7 日满意率 / 无结果率等	反馈与检索质量	user_feedbacks 等
重复检测 / 待复核预警	运营	定时或仪表盘逻辑

六、业务流程详细说明

6.1 文档入库流程

【开始】



① 文档进入 watch_directory / 上传接口 / 博客爬取或发布同步



- ② 系统自动（定时约 30 分钟或 POST /scan）：
- a. SHA-256 哈希去重（移动/重命名可追踪）
 - b. 解析（md/docx/txt 优先章节切片；pdf/doc；Excel→Markdown 表；图片/视频→视觉描述）
 - c. 清洗（Word 域代码、纯目录/纯链接/噪声）
 - d. 分块（章节硬边界 + 语义边界；表格/代码结构保护）
 - e. 向量化写入 Chroma，review_status=pending
 - f. 更新 file_index；重建 BM25；清查询缓存
- （图谱抽取不在本步自动 apply 进正式库）



- ③ 业务员在【知识块审核工作台】处理 pending：
- 通过 → approved（可被检索）
 - 驳回 → rejected
 - 可改章节标题、doc_category
 - 无合并/拆分/块内改文 → 切错则驳回后由开发侧重切



④ approved 后进入检索集合



【结束】

6.2 用户问答流程（含反问场景）

【开始】

↓

① 用户在【智能对话页面】输入问题

↓

② 闲聊/敏感分流；否则进入问答管线

↓

③ 提问前歧义预检（/query/clarify）

└─ 命中 → 反问卡片 → 用户选择过滤条件 → 继续

└─ 未命中 → 继续

↓

④ 上下文文化 + QueryPlanner

↓

⑤ [可选] 图谱准备：链接实体 / 扩召回取块 / 改写检索 query

↓

⑥ Hybrid 正式检索（approved + 可选分类/知识库过滤）

↓

⑦ [可选] 图侧与文本路融合（席位控噪 + 保护文本 top1）

↓

⑧ [可选] Rerank → 后处理（结构化加权 + Graph Intent）

↓

⑨ 组装 context（仅 chunk 原文 + 可选实体消歧提示）→ LLM 生成（SSE）

↓

⑩ 展示来源/证据；用户反馈有用/无用

↓

【结束】

6.3 图谱维护流程

【开始】

↓

- ① 方式一：规则管线 ± LLM 抽取 → extraction_candidates
 - SectionPath / TableField / ConfigBlock 等确定性抽取
 - 可选 LLM 语义补实（配置开关）
 - 指纹去重进批次

↓

- ② 方式二：产品主干 / domain_catalog / Profile 等 JSON 同步进 staging

↓

- ③ 审批：【图谱候选审批台】或 CLI (run_graph_build.py)
 - 分拆审批：禁止对敏感 mode 滥用 --approve-all
 - apply 需三重确认（DB 路径 / 批次 / 备份）

↓

- ④ 写入正式表：entities / aliases / relations / entity_chunk_links / fields / ...

↓

- ⑤ 画布：查看、过滤、展开邻居；主干预览改 JSON（不直接当正式写）

↓

- ⑥ 审计 / Stale 清理 / 质量 / Task8.1 Gate 等运维命令

↓

- ⑦ 运行时：仅按配置介入检索管线（Intent / 扩召回融合 / 改写 / 消歧提示）

↓

【结束】

七、部署与模型接入（对应原版「Open WebUI 集成」）

原版保留 Open WebUI + 多独立服务。现状为完全自研单体 + 双容器部署，对照如下：

7.1 与原集成方案对照

原版组件	原策略	现状
Open WebUI 前端	保留	✗ 未使用；Vue3 自研（对话/审核/画布等）
Open WebUI 对话/知识库 API	保留/换源	✗；自研 /query 、 /query/stream 、 审核与图谱 API
Ollama + Qwen	保留	✓ 仍可用；并支持按角色接 Google / OpenAI
Pipelines 智能体	扩展	✗；逻辑在 FastAPI rag.py 管线内
旧 Chunk 迁移	迁移	以受控重建 / 审核态治理为主，非原版 is_active 版本页

7.2 现行服务形态

服务	职责	部署方式
rag-service	问答管线、入库扫描、审核、图谱管理、质量、QA trace	FastAPI（Docker 内 10605；本地 run.py ）
rag-web	静态前端	Nginx + Vue dist（对外 :80，/api 反代）
gpu-agent （可选）	显存指标	集成目录，主进程可自动拉起 :11435
Ollama / 外部 LLM	推理与 embedding	按 config 各角色 provider 配置

配置矩阵简述： config-local.ini（纯本地）、 config.ini / config-mix.ini（开发混合）、 config-prod.ini（生产模板：默认关 Rerank、关图检索、关抽取 LLM）。

八、非功能性需求

8.1 性能要求 / 实测

指标	原版要求	现状参考
普通问答响应	≤ 5 秒	视模型与是否 Rerank/开图；检索段 Hybrid 历史约 ~200ms 量级（不含生成）
含反问	卡片 ≤ 2 秒	clarify 依赖 helper LLM，无统一 SLA 承诺
检索质量	—	Hybrid+Rerank：标准集 Recall@3 88.89% ；难例集 90.97% ；黄金集 86.67%
GraphRAG	—	第 4 轮 A/B PASS ；融合控噪已落地； 生产默认仍关图
图谱画布	≥500 节点 30fps	渐进展开/过滤为主，未按原版指标单独验收

8.2 可用性要求

指标	原版	现状
可用性 99.5%	要求	未作为正式 SLA 度量
数据备份	每日自动	受控重建前备份；运维侧可对 db/chroma 做备份，非原版「每日自动」产品化
模型容错	自动切备选	GPU 显存自适应推荐/降级；gpu-agent 不可达时 保守不降级

8.3 安全要求

要求	原版	现状
用户认证	继承 Open WebUI	 无登录权限体系
操作日志	知识块/图谱变更留痕	图谱 apply/审批有治理审计；知识块编辑留痕有限
数据隔离	多用户后续	仅两固定知识库，无多租户
敏感数据过滤	上传脱敏	 未实现；回答侧有敏感拒答类逻辑

8.4 可扩展性要求

扩展方向	现状预留
地图展示	仅 geo_wkt
多租户	未加 tenant_id
多模态	图片/视频入库描述 + 图片问答已有；非原版「工具集」形态
外部数据源	博客爬取/同步；分类枚举含「博客/其他」等

九、实施优先级与排期（对照原版五阶段）

原版为 12 周五阶段排期。下表改为 **落地对照**（非新排期）：

阶段	原版核心交付	现状结论
第一阶段： 数据基础设施	分类表/实体表/关系表、清洗分块、元数据入向量库	 向量元数据 + SQLite 图谱已建成；分类为枚举+catalog，非树表

阶段	原版核心交付	现状结论
第二阶段： 知识块审核	审核台 + 关联实体	✅ 审核台通过/驳回/改标题分类；❌ 无合并拆分与审核台关联实体
第三阶段： 智能体核心	调度服务 + 反问 + 检索图谱扩展	✅ 管线 RAG + clarify + Hybrid±图；❌ 无独立调度服务/偏好记忆/超时综合
第四阶段： 画布与仪表盘	画布全操作 + 仪表盘	✅ 画布与仪表盘可用；画布能力弱于原版（无快照/合并等）；另增候选审批台与 QA 调试
第五阶段： 全量迁移与上线	旧 chunk 迁移、培训	✅ Docker 双容器与生产模板；GraphRAG 生产默认关；持续以受控重建/审批治理数据

相对原版的明确缺口（摘要）：Open WebUI/认证、分类树与版本页、块合并拆分与审核台实体关联、用户偏好与反问超时、关系当答案、生产默认开图未批准。

文档结束